

Agent 运行报告

实验名称: 20260802-162847
运行时间: 2026-08-02T08:28:58.816199+00:00
模型: deepseek-v4-pro (temperature=0, max_tokens=100000)
Agent 配置: max_rounds=60, num_threads=4, rollout_number=1

运行概览

指标	数值
任务总数	50
成功任务	50 
失败任务	0 
成功率	100.00%

评分结果

指标	数值
正确任务	31 / 50
本次准确率	62.00%
全数据集得分率	5.67% (31/547)

Schema Router 硬隔离

指标	数值
模式	strict
有效路由	50 / 50
Router 失败	0
平均压缩前物理表	101.04
平均压缩后物理表	39.92
白名单越界尝试	1
Router Token	1724484

每题路由压缩

Instance ID	Rollout	压缩前	压缩后	压缩率
sf_bq001	0	366	28	92.35%
sf_bq002	0	366	181	50.55%
sf_bq003	0	366	122	66.67%
sf_bq004	0	366	31	91.53%
sf_bq008	0	366	31	91.53%
sf_bq009	0	366	213	41.80%
sf_bq010	0	366	31	91.53%
sf_bq011	0	92	7	92.39%
sf_bq026	0	3	2	33.33%
sf_bq027	0	3	1	66.67%
sf_bq029	0	3	1	66.67%
sf_bq033	0	3	1	66.67%
sf_bq036	0	6	3	50.00%
sf_bq052	0	59	8	86.44%
sf_bq091	0	3	2	33.33%
sf_bq099	0	3	2	33.33%
sf_bq100	0	6	1	83.33%
sf_bq101	0	6	3	50.00%
sf_bq127	0	4	3	25.00%
sf_bq128	0	59	9	84.75%
sf_bq180	0	6	2	66.67%
sf_bq182	0	38	2	94.74%
sf_bq191	0	38	2	94.74%
sf_bq192	0	38	5	86.84%
sf_bq193	0	6	4	33.33%
sf_bq207	0	46	3	93.48%
sf_bq209	0	3	1	66.67%
sf_bq210	0	3	1	66.67%
sf_bq211	0	3	1	66.67%
sf_bq212	0	3	1	66.67%

Instance ID	Rollout	压缩前	压缩后	压缩率
sf_bq213	0	3	1	66.67%
sf_bq214	0	4	2	50.00%
sf_bq215	0	3	1	66.67%
sf_bq216	0	4	3	25.00%
sf_bq217	0	38	2	94.74%
sf_bq221	0	3	2	33.33%
sf_bq222	0	3	2	33.33%
sf_bq223	0	3	2	33.33%
sf_bq224	0	38	2	94.74%
sf_bq225	0	6	2	66.67%
sf_bq233	0	6	3	50.00%
sf_bq246	0	59	8	86.44%
sf_bq247	0	4	2	50.00%
sf_bq248	0	6	4	33.33%
sf_bq268	0	366	366	0.00%
sf_bq269	0	366	61	83.33%
sf_bq270	0	366	90	75.41%
sf_bq275	0	366	366	0.00%
sf_bq374	0	366	366	0.00%
sf_bq420	0	46	9	80.43%

任务得分详情

Instance ID	得分	对话轮次	工具调用	状态	错误信息
sf_bq001	 1	17	17	成功	-
sf_bq002	 0	17	19	失败	Result Error
sf_bq003	 1	22	24	成功	-
sf_bq004	 0	19	19	失败	Result Error
sf_bq008	 0	17	17	失败	Result Error
sf_bq009	 0	25	25	失败	Result Error
sf_bq010	 1	25	27	成功	-

Instance ID	得分	对话轮次	工具调用	状态	错误信息
sf_bq011	✓ 1	15	16	成功	-
sf_bq026	✗ 0	16	20	失败	Result Error
sf_bq027	✓ 1	32	32	成功	-
sf_bq029	✓ 1	8	8	成功	-
sf_bq033	✓ 1	18	18	成功	-
sf_bq036	✓ 1	16	17	成功	-
sf_bq052	✓ 1	20	25	成功	-
sf_bq091	✓ 1	16	18	成功	-
sf_bq099	✗ 0	21	24	失败	Result Error
sf_bq100	✓ 1	12	12	成功	-
sf_bq101	✓ 1	40	41	成功	-
sf_bq127	✓ 1	34	34	成功	-
sf_bq128	✗ 0	36	46	失败	Result Error
sf_bq180	✗ 0	36	45	失败	Result Error
sf_bq182	✓ 1	12	16	成功	-
sf_bq191	✓ 1	13	14	成功	-
sf_bq192	✓ 1	17	28	成功	-
sf_bq193	✗ 0	39	45	失败	Result Error
sf_bq207	✓ 1	22	28	成功	-
sf_bq209	✓ 1	26	26	成功	-
sf_bq210	✗ 0	15	15	失败	Result Error
sf_bq211	✓ 1	14	14	成功	-
sf_bq212	✓ 1	16	17	成功	-
sf_bq213	✗ 0	14	14	失败	Result Error
sf_bq214	✓ 1	22	23	成功	-
sf_bq215	✓ 1	30	30	成功	-
sf_bq216	✓ 1	14	17	成功	-
sf_bq217	✓ 1	17	23	成功	-
sf_bq221	✗ 0	30	33	失败	Result Error
sf_bq222	✗ 0	22	28	失败	Result Error

Instance ID	得分	对话轮次	工具调用	状态	错误信息
sf_bq223	✔ 1	29	29	成功	-
sf_bq224	✔ 1	10	15	成功	-
sf_bq225	✔ 1	15	18	成功	-
sf_bq233	✘ 0	31	34	失败	Result Error
sf_bq246	✘ 0	22	35	失败	Result Error
sf_bq247	✔ 1	10	14	成功	-
sf_bq248	✔ 1	21	28	成功	-
sf_bq268	✔ 1	27	27	成功	-
sf_bq269	✔ 1	17	17	成功	-
sf_bq270	✘ 0	19	20	失败	Result Error
sf_bq275	✘ 0	23	23	失败	Result Error
sf_bq374	✘ 0	25	25	失败	Result Error
sf_bq420	✘ 0	55	60	失败	Result Error

 工具使用统计

工具名称	调用次数	占比
execute_sql	852	69.8%
describe_table	106	8.7%
search_schema	73	6.0%
terminate	64	5.2%
build_union_sql	53	4.3%
get_sql_text	35	2.9%
resolve_table_set	25	2.0%
read_query_result	12	1.0%

 性能剖面

指标	数值
Agent 墙钟时间	3015.82 秒
已剖析任务	50
平均任务耗时	237.22 秒

指标	数值
P95 任务耗时	530.63 秒
最慢任务	sf_bq275 (594.95 秒)
模型累计耗时	8468.07 秒
模型调用 / 重试	1089 / 0
SQL 累计耗时	3393.90 秒
SQL 调用 / 错误	852 / 113
最大 SQL 长度	71055 字符
terminate 调用 / 拒绝	64 / 14

最慢任务

Instance ID	总耗时 (秒)	模型耗时 (秒)	SQL耗时 (秒)	SQL调用/错误	terminate拒绝	最大SQL字符
sf_bq275	594.95	319.86	267.80	11/1	0	71055
sf_bq420	548.15	410.53	133.40	50/4	0	2447
sf_bq268	530.63	403.53	124.52	17/2	0	59931
sf_bq027	470.90	121.18	345.23	28/4	0	381
sf_bq128	429.50	336.57	100.25	37/3	0	1276
sf_bq374	369.95	303.93	63.09	14/2	0	68793
sf_bq101	366.00	287.14	75.76	34/3	1	1095
sf_bq003	360.40	302.05	55.67	15/4	0	34199
sf_bq002	348.62	213.64	132.20	8/2	0	46203
sf_bq215	326.56	266.19	57.22	24/2	0	1788

 对话统计

指标	平均值
对话轮次	21.8
工具调用次数	24.4
消息总数	47.2

 失败分析

共 19 个任务失败：

- **sf_bq004:** Result Error
- **sf_bq008:** Result Error
- **sf_bq002:** Result Error
- **sf_bq026:** Result Error
- **sf_bq009:** Result Error
- **sf_bq099:** Result Error
- **sf_bq180:** Result Error
- **sf_bq128:** Result Error
- **sf_bq210:** Result Error
- **sf_bq193:** Result Error
- **sf_bq213:** Result Error
- **sf_bq221:** Result Error
- **sf_bq222:** Result Error
- **sf_bq233:** Result Error
- **sf_bq246:** Result Error
- **sf_bq270:** Result Error
- **sf_bq420:** Result Error
- **sf_bq275:** Result Error
- **sf_bq374:** Result Error

配置文件

```
experiment:
  name: first-50-test
  results_root: methods/spider-agent-tc/results
  resume: true
secrets_file: methods/spider-agent-tc/configs/secrets.yaml
paths:
  input_file: spider2-snow/spider2-snow.jsonl
  databases: spider2-snow/resource/databases
  documents: spider2-snow/resource/documents
  system_prompt: methods/spider-agent-tc/prompts/spider_agent.txt
tasks:
  instance_ids: []
  index_ranges:
    - 0-49
  databases: []
  sample_size: null
  seed: 42
  order: seeded_shuffle
model:
  name: deepseek-v4-pro
  temperature: 0
  top_p: 1
  max_tokens: 100000
  request_timeout_seconds: 180
  retry:
    max_attempts: 3
    initial_delay_seconds: 1
```

```
    backoff_multiplier: 2
    max_delay_seconds: 10
agent:
  max_rounds: 60
  num_threads: 4
  rollout_number: 1
schema_router:
  enabled: true
  prompt: methods/spider-agent-tc/prompts/schema_router.txt
  model:
    name: deepseek-v4-flash
    temperature: 0
    top_p: 1
    max_tokens: 12000
    request_timeout_seconds: 180
  retry:
    max_attempts: 3
    initial_delay_seconds: 1
    backoff_multiplier: 2
    max_delay_seconds: 10
max_rounds: 10
max_tool_calls: 24
num_threads: 4
sample_rows: 1
max_sample_chars: 4000
integration:
  mode: strict
  include_tiers:
    - required
    - supporting
    - possible
  failure_policy: fail_task
server:
  host: 127.0.0.1
  preferred_port: 5000
  workers_per_tool: 8
  startup_timeout_seconds: 20
  request_timeout_seconds: 150
tools:
  catalog:
    page_size: 50
    max_page_size: 100
    sample_rows: 3
    max_sample_chars: 12000
  sql:
    mode: live
    timeout_seconds: 120
    preview_rows: 20
    max_page_size: 100
  submission:
    require_executed: true
    reject_empty: true
preflight:
  check_model: true
```



```
check_snowflake: true
auto_evaluate:
  enabled: true
  timeout: 300
  max_workers: 4
```

报告生成时间: 2026-08-02T17:26:02.664299

结果目录: C:\Users\ulna\Desktop\Spider2\methods\spider-agent-tc\results\first-50-test\20260802-162847