

鲜兴元 2026.07.27-2026.08.02 周报

一、本周工作内容

本周主要围绕 Spider2 的 Agent 系统开展展开，工作集中在 `methods/spider-agent-tc` 目录下。重点完成了 Agent 框架的 LangGraph 改造、主 Agent 工具链的重新设计、Schema Router 表压缩模块的开发与全量评测，以及 Router 接入主 Agent 后的端到端验证。主要包括以下四个方面：

- 1. 完成 Agent 框架的 LangGraph 改造，搭建自动评分与实验管理基础设施。
- 2. 重新设计主 Agent 工具链，将原有单一 SQL 执行工具拆分为结构化多工具体系，准确率从 52.08% 提升至 63.27%。
- 3. 开发 Schema Router 表压缩模块并完成 120 题全量评测，物理表 Micro Recall 达到 97.78%，平均压缩率 70.03%。

1. LangGraph 框架改造与实验基础设施建设

本周首先对 Agent 框架进行了 LangGraph 改造，将原有的线性对话循环重构为基于状态图的 Agent 工作流，使工具调用、结果回传和轮次控制更加清晰。同时完成了以下基础设施搭建：

- 自动评分模块：每次运行结束后自动对比 Gold SQL 结果，生成 REPORT.md 报告。
- 实验管理：一个 YAML 配置文件对应一组运行结果，结果目录以时间戳自动命名，支持断点续跑。
- 运行监控：控制台精简输出、显示实时时间与推理速度、动态写入日志文件。
- 工具并发执行：支持同一轮次内多个工具调用并发执行，减少等待时间。

2. 主 Agent 工具链重新设计

在框架改造完成后，对主 Agent 的工具链进行了重新设计。原有方案仅提供 `execute_snowflake_sql` 和 `execute_bash` 两个通用工具，Agent 需要自行探索数据库结构，效率较低且容易出错。新方案将工具链拆分为 9 个结构化工具：`search_schema`（模式搜索）、`describe_table`（表结构描述）、`resolve_table_set`（表集合解析）、`execute_sql`（SQL 执行）、`build_union_sql`（联合查询构建）、`get_sql_text`（SQL 文本获取）、`get_task_context`（任务上下文获取）、`read_query_result`（结果读取）和 `terminate`（终止提交）。

同时在初始 Prompt 中加入了所有数据库的 Schema 概览信息，并更新了引导策略。修改前后在同一组 50 题上进行了对比实验：

指标	修改前（0729）	修改后（0730）	变化量
任务成功率	96.00%（48/50）	98.00%（49/50）	+2.00%（+1）
准确率	52.08%（25/48）	63.27%（31/49）	+11.19%（+6）
全数据集得分率	4.57%（25/547）	5.67%（31/547）	+1.10%（+6）
平均对话轮次	26.1	25.3	-0.8

备注：Snow数据集总共有500+题目，我们从500题随机抽取50个题，并固定该50题作为开发集。先在这50题上测试改进效果。

工具链改造后，Agent 不再需要大量 bash 探索（原占比 30%），转而使用结构化 schema 工具主动获取表信息，SQL 执行效率和结果正确率均有明显提升。

3. Schema Router 表压缩模块

本周还开发了 Schema Router 模块，用于在 Agent 正式推理前对大规模数据库进行表级压缩，减少 Agent 需要处理的 Schema 信息量。Router 根据任务问题语义，从数据库的全量物理表中筛选出与任务相关的候选表集合，并按 required / supporting / possible 三级置信度分层输出。

在 120 道官方给出标准答案 SQL 题目上完成了全量评测，主要结果如下：

指标	结果
物理表题级全覆盖率	94.17%
物理表 Micro Recall	97.78%
物理表 Macro Recall	97.73%
平均物理表压缩率	70.03%
平均表族压缩率	67.91%
Recall@5	96.18%
Recall@10	97.73%

当前针对表压缩效果较好，大多数题目能够从几十张甚至上百张表筛选出低于10张的有效表。大幅减少了后续主agent的探索范围。

评测中 120 题全部完成，无失败 Rollout。113/120 题实现了物理表全覆盖，7 题存在部分遗漏。具体详细的压缩结果参考附件。

二、本周学习内容与收获

本周最大的收获是理解了 Agent 工具设计对最终效果的显著影响。在模型和 Prompt 基本不变的情况下，仅通过将通用工具拆分为语义明确的结构化工具，准确率就提升了约 11 个百分点。这说明对于 Text-to-SQL 类任务，降低 Agent 每一步的决策难度比增加模型能力更为关键。Agent 不需要"什么都能做"的万能工具，而是需要在正确的时机获得正确的信息。

在 Schema Router 的开发中，进一步认识到大规模数据库（如 CENSUS_BUREAU_ACS_2 有 296 张表、TCGA_MITELMAN 有 176 张表）直接将全量 Schema 塞入上下文是不可行的。表压缩不仅是性能优化，更是让 Agent 能够聚焦于正确表集合的必要前置步骤。70% 的平均压缩率意味着 Agent 只需处理原来不到三分之一的表，同时 97.78% 的召回率保证了信息损失极小。

三、下周计划

- 1. 优化 Schema Router 的验收指标，重点解决 7 道未全覆盖题目和非法引用问题，争取通过全量验收门槛。
- 2. 在 Router 接入主 Agent 后，重新运行 50 题对比实验，验证表压缩对端到端准确率的实际提升效果。
- 3. 分析当前 18 道仍然失败的题目，归类错误原因（Schema 理解错误、SQL 语法问题、数据理解偏差等），针对性优化 Prompt 和工具链。
- 4. 继续学习 Spider2 高分榜开源方案中的 Agent 设计思路。

四、当前问题

1. Schema Router 当前版本存在 75 次非法/越权引用尝试，虽然不影响召回率，但说明 Router 在边界约束上还需加强。
2. Schema Router虽然压缩率足够高，但存在一定的遗漏率，如果遗漏一个表，则会导致后续主agent无法找到正确的表，进而不可能得到正确答案。

五、附件

50题评分报告.pdf

表压缩效果报告.pdf